

Procesamiento de Lenguaje Natural / TP

Detección de rumores en medios sociales

- El uso de las redes sociales para el descubrimiento de noticias se ha hecho muy popular en los últimos años.
 - No solo para conocer los sucesos, sino que también los periodistas las usan para recolectar noticias.
- Esto es posible debido a que permiten a sus usuarios publicar y compartir información desde cualquier lugar del mundo en cualquier momento.
- La velocidad de publicación de noticias durante eventos (ataques terroristas, manifestaciones, ...) hace que mucha de esa información **NO** se encuentre verificada.
- Entonces...

Detectar la información que no se encuentra verificada puede ser útil para limitar la difusión de información que puede resultar **falsa**.







Rumour has it

Un rumor es una historia que circula de veracidad cuestionable. En apariencia creíble pero difícil de verificar que logra producir la sufiente "ansiedad" o "excepticismo", lo que motiva a averiguar si es verdad o no.



Rumour has it

Un rumor es una historia que circula de veracidad cuestionable. En apariencia creíble pero difícil de verificar que logra producir la sufiente "ansiedad" o "excepticismo", lo que motiva a averiguar si es verdad o no.

- La presencia de rumores de rumores en hordas de tweets dificulta que los usuarios puedan distinguir entre la información verificada y los rumores.
- Hace más difícil que los periodistas puedan encontrar noticias.



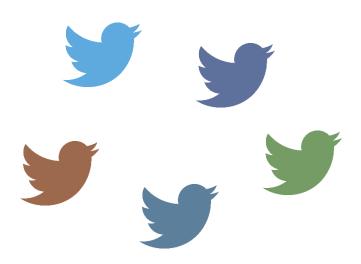
Cuál es el objetivo?

Detectar aquellos tweets que contienen información que todavía no ha sido verificada (los rumores), distinguiéndola de lo que no son rumores!



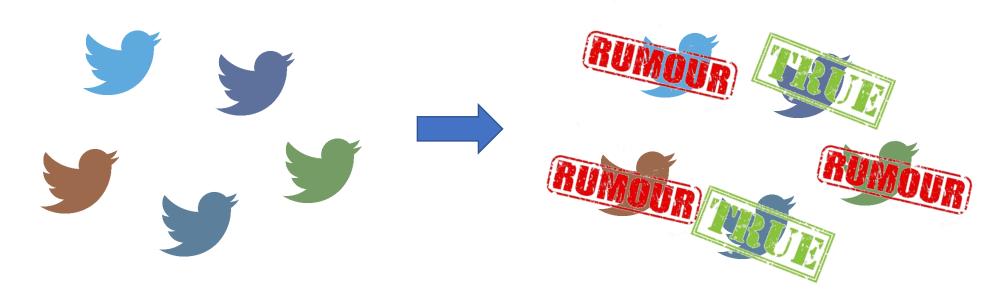
Cuál es el objetivo?

Detectar aquellos tweets que contienen información que todavía no ha sido verificada (los rumores), distinguiéndola de lo que no son rumores!



Cuál es el objetivo?

Detectar aquellos tweets que contienen información que todavía no ha sido verificada (los rumores), distinguiéndola de lo que no son rumores!

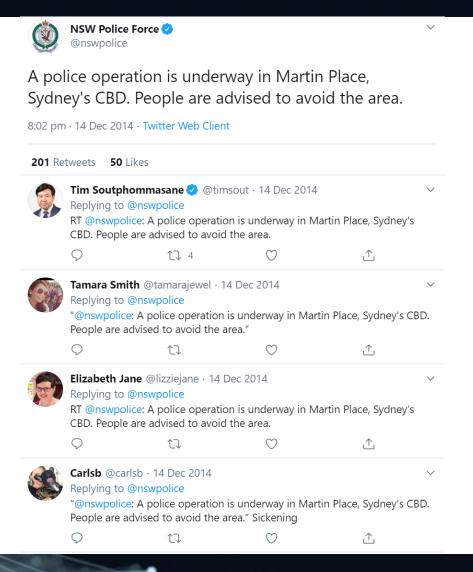


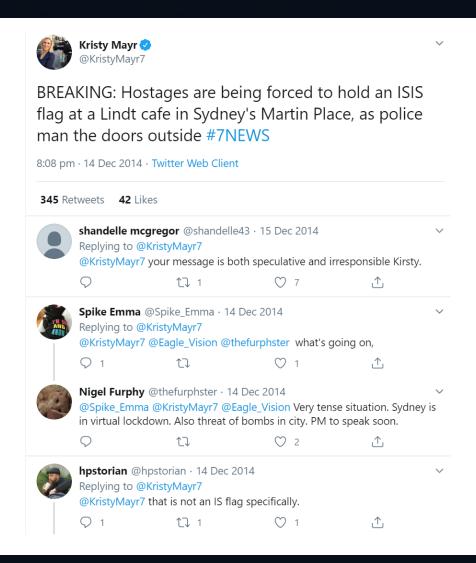


- Sydney siege.
 - Un hombre armado tomó como rehenes a 10 clientes y 8 empleados en un local de Lindt en Sydney, Australia, el 15 de Diciembre de 2014.

Evento	Rumours	Non-rumours	Total
Sydney Siege	522 (42.8 %)	699 (57.2 %)	1.221









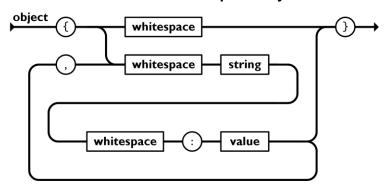


Y los datos?

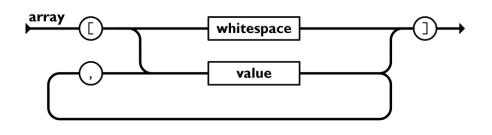
- Sydney siege.
 - Un hombre armado tomó como rehenes a 10 clientes y 8 empleados en un local de Lindt en Sydney, Australia, el 15 de Diciembre de 2014.

Evento	Rumours	Non-rumours	Total
Sydney Siege	522 (42.8 %)	699 (57.2 %)	1.221

Formato JSON → JavaScript Object Notation



Cada **objeto** es una colección de pares <nombre atributo, valor atributo>.



Los **objetos** se pueden combinar en la forma de una secuencia ordenada denominada **array**.

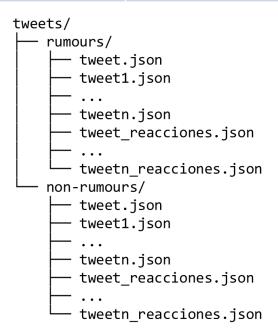




- Sydney siege.
 - Un hombre armado tomó como rehenes a 10 clientes y 8 empleados en un local de Lindt en Sydney, Australia, el 15 de Diciembre de 2014.

Evento	Rumours	Non-rumours	Total
Sydney Siege	522 (42.8 %)	699 (57.2 %)	1.221

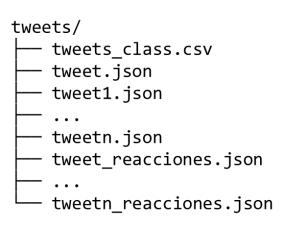
- Formato JSON → JavaScript Object Notation
- Por cada Tweet, se tiene:
 - Información completa.
 - Información completa de las reacciones.
 - Clase (Rumor o no rumor?)



- Sydney siege.
 - Un hombre armado tomó como rehenes a 10 clientes y 8 empleados en un local de Lindt en Sydney, Australia, el 15 de Diciembre de 2014.

Evento	Rumours	Non-rumours	Total
Sydney Siege	522 (42.8 %)	699 (57.2 %)	1.221

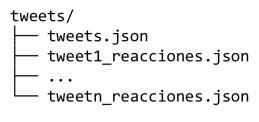
- Formato JSON → JavaScript Object Notation
- Por cada Tweet, se tiene:
 - Información completa.
 - Información completa de las reacciones.
 - Clase (Rumor o no rumor?)



- · Sydney siege.
 - Un hombre armado tomó como rehenes a 10 clientes y 8 empleados en un local de Lindt en Sydney, Australia, el 15 de Diciembre de 2014.

Evento	Rumours	Non-rumours	Total
Sydney Siege	522 (42.8 %)	699 (57.2 %)	1.221

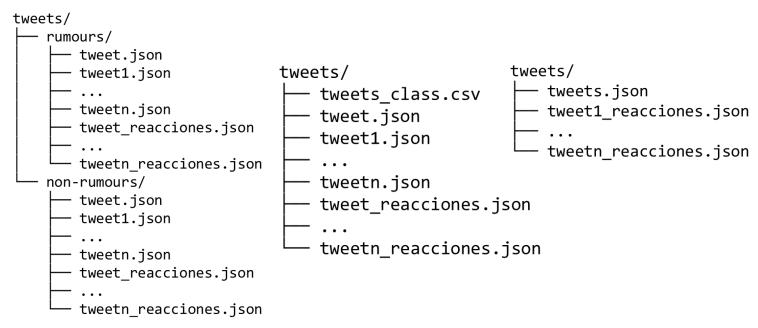
- Formato JSON → JavaScript Object Notation
- Por cada Tweet, se tiene:
 - Información completa.
 - Información completa de las reacciones.
 - Clase (Rumor o no rumor?)



- Sydney siege.
 - Un hombre armado tomó como rehenes a 10 clientes y 8 empleados en un local de Lindt en Sydney, Australia, el 15 de Diciembre de 2014.

Evento	Rumours	Non-rumours	Total
Sydney Siege	522 (42.8 %)	699 (57.2 %)	1.221

- Formato JSON → JavaScript Object Notation
- Por cada Tweet, se tiene:
 - Información completa.
 - Información completa de las reacciones.
 - Clase (Rumor o no rumor?)



Formato de los datos

{"contributors":null,"truncated":false,"text":"This photo, reported to be of suspected Ottawa shooter Michael Zehar Bibeau, came from suspended ISIS Twitter account http:\\/t.co\/QiM55Gu93N","in_reply_to_status_id":null,"id":525072912957452289,"favorite_count":208,"source":"TweetDeck<\a>","retweeted":false,"coordinates":null,"entities":{"symbols":[],"media":[{"expanded_url":"http:\\/t witter.com\/CP24\ystatus\\$525072912957452289\photo\/1","display_url":"pic.twitter.com\/QiM55Gu93N","url":"http:\\/t.co\/QiM55Gu93N","media_url_https":"https:\\/pbs.twimg.com\/media\/BolvCCXCUAAcPFg.jpg","id_str":"525072912349286400","sizes":{"hi*.401,"resizee":"fiit","w":533},"thumb":{"h":255,"resizee":"crop","w":150},"id=str":"50),"idices":[118,140],"typee":"photo", iid":525072912349286400,"media_url":"http:\\/pbs.twimg.com\/media\/BolvCCXCUAAcPFg.jpg"],"hashtags":[],"user_mentions":[],"trends"::[],"urls"::[]},"in_reply_to_screen_name":null,"id_str":"525072912957452289","retweet_count":634,"in_reply_to_user_id":null,"favorited":false, user":("follow_request_sent":null,"profile_use_background_image":true,"default_profile_image":false,"id":19636948,"verified":true,"profile_image_url_https":"https:\\/pbs.twimg.com\/profile_images\/4594289 06571804672\/jx_823KA_normal.png","profile_sidebar_fill_color":"FFFFFF","profile_text_color":"FB1818","followers_count":638667,"profile_background_images\/266977293\/cp24_twitter_background_image_url_https":"https:\\/pbs.twimg.com\/profile_background_images\/266977293\/cp24_twitter_background_sound_spg","utc_offset":-14400,"statuses_count":83131,"description":"Official account of CP24 - Toronto's #1 source for breaking news. We are the most followed newsroom in Canada and our account is LIVE 24 hours a

day.","friends_count":367,"location":"Toronto","profile_link_color":"02A0D9","profile_image_url":"http:\\/pbs.twimg.com\/profile_images\/459428906571804672\/jx_823KA_normal.png","fol lowing":null,"geo_enabled":false,"profile_banner_url":"https:\\/pbs.twimg.com\/profile_banners\/19636948\/1398372693","profile_background_image_url":"http:\\/pbs.twimg.com\/profile_background_images\/266977293\/cp24_twitter_background4.jpg","name":"CP24","lang":"en","profile_background_tile":true,"favourites_count":6,"screen_name":"CP24","notifications":null," url":"http:\\/www.cp24.com","created_at":"Wed Jan 28 04:56:13 +0000 2009","contributors_enabled":false,"time_zone":"Eastern Time (US & Canada)",
"protected":false,"default_profile":false,"is_translator":false},"geo":null,"in_reply_to_user_id_str":null,"possibly_sensitive":false,"lang":"en","created_at":"Wed Oct 22 23:55:12 +0000

2014", "filter_level": "low", "in_reply_to_status_id_str":null, "place":null, "

extended_entities":{"media":[{"expanded_url":"http:\/\twitter.com\/CP24\/status\/525072912957452289\/photo\/1","display_url":"pic.twitter.com\/QiM55Gu93N","url":"http:\/\t.co\/QiM55Gu93N","media_url_https:"https:\/\pbs.twimg.com\/media\/B0lvCCXCUAAcPFg.jpg","id_str":"525072912349286400","sizes":{"large":{"h":401,"resize":"fit","w":533},"small":{"h":255,"resize":"fit","w":340},"medium":{"h":401,"resize":"fit","w":533},"thumb":{"h":150,"resize":"crop","w":150}},"indices":[118,140],"type":"photo","id":525072912349286400,"media_url":"http:\/\pbs.twimg.com\/media\/B0lvCCXCUAAcPFg.jpg"}]}}



Formato de los datos

{"contributors":null,"truncated":false,"text":"This photo, reported to be of suspected Ottawa shooter Michael Zehar Bibeau, came from suspended ISIS Twitter account http:\/\t.co\/QiM55Gu93N","in_reply_to_status_id":null,"id":525072912957452289,"favorite_count":208,"source":"TweetDeck<\a>","retweeted":false,"coordinates":null,"entities":{"symbols":[],"media":[{"expanded_url":"http:\/\t witter.com\/CP24\ystatus\y525072912957452289\/photo\/1","display_url":"pic.twitter.com\/QiM55Gu93N","url":"http:\/\t.co\/QiM55Gu93N","media_url_https":"https:\/\phos.twimg.com\/media\/BolvCCXCUAAcPFg.jpg","id_str":"525072912349286400","sizes":{"hit**,01,"resizee":"fit","w":533},"small":{"h*:255,"resizee":"fit","w":340},"mediam":{"h*:401,"resizee":"fit","w":533},"thumb":{"h*:150,"resizee":"rop","w":150}},"id=str":"525072912349286400,"media_url":"http:\/\phos.twimg.com\/media\/BolvCCXCUAAcPFg.jpg"}],"hashtags":[],"user_mentions":[],"trends":[],"urls":[]},"in_reply_to_screen_name":null,"id_str":"525072912957452289","retweet_count":634,"in_reply_to_user_id":null,"favorited":false, user":("follow_request_sent":null,"profile_use_background_image":true,"default_profile_image":false,"id":19636948,"verified":true,"profile_image_url_https":"https:\/\pbs.twimg.com\/profile_images\/4594289 06571804672\/jx_823KA_normal.png","profile_sidebar_fill_color":"FFFFFF","profile_text_color":"FB1818","followers_count":638667,"profile_background_images\/266977293\/cp24_twitter_background4.jpg","utc_offset":-14400,"statuses_count":83131,"description":"Official account of CP24 - Toronto's #1 source for breaking news. We are the most followed newsroom in Canada and our account is LIVE 24 hours a

day.","friends_count":367,"location":"Toronto","profile_link_color":"02A0D9","profile_image_url":"http:\\/pbs.twimg.com\/profile_images\/459428906571804672\/jx_823KA_normal.png","fol lowing":null,"geo_enabled":false,"profile_banner_url":"https:\\/pbs.twimg.com\/profile_banners\/19636948\/1398372693","profile_background_image_url":"http:\\/pbs.twimg.com\/profile_background_images\/266977293\/cp24_twitter_background4.jpg","name":"CP24","lang":"en","profile_background_tile":true,"favourites_count":6,"screen_name":"CP24","notifications":null,"url":"http:\\/www.cp24.com","created_at":"Wed Jan 28 04:56:13 +0000 2009","contributors_enabled":false,"time_zone":"Eastern Time (US & Canada)",
"protected":false,"default_profile":false,"is_translator":false},"geo":null,"in_reply_to_user_id_str":null,"possibly_sensitive":false,"lang":"en","created_at":"Wed Oct 22 23:55:12 +0000

2014","filter_level":"low","in_reply_to_status_id_str":null,"place":null," extended_entities":{"media":[{"expanded_url":"http:\/\t.co\/QiM5 5Gu93N","url":"http:\/\t.co\/QiM5 5Gu93N","media_url_https":"https:\/\pbs.twimg.com\/media\/B0lvCCXCUAAcPFg.jpg","id_str":"525072912349286400","sizes":{"large":{"h":401,"resize":"fit","w":533},"small":{"h":255,"resize":"fit","w":340},"medium":{"h":401,"resize":"fit","w":533},"thumb":{"h":150,"resize":"crop","w":150}},"indices":[118,140],"type":"photo","id":525072912349286400,"media_url":"http:\/\pbs.twimg.com\/media\/B0lvCCXCUAAcPFg.jpg"}]}}



Formato de los datos

{"contributors":null,"truncated":false,"text":"This photo, reported to be of suspected Ottawa shooter Michael Zehar Bibeau, came from suspended ISIS Twitter account http:\/\t.co\/QiM55Gu93N","in_reply_to_status_id":null,"id":525072912957452289,"favorite_count":208,"source":"TweetDeck<\da>","retweeted":false,"coordinates":null,"entities":{"symbols":[],"media":[{"expanded_url":"http:\/\dt witter.com\/CP24\/status\/525072912957452289\/photo\/1","display_url":"pic.twitter.com\/QiM55Gu93N\","url":"http:\/\dt.co\/QiM55Gu93N\","media_url_https:\"https:\/\photo.twitter.com\/QiM55Gu93N\","url":"http:\/\dt.co\/QiM55Gu93N\","media_url_https:\"https:\/\photo.twitter.com\/QiM55Gu93N\","media_url_https:\"https:\/\photo.twitter.com\/QiM55Gu93N\","media_url_https:\"https:\/\photo.twitter.com\/QiM55Gu93N\","media_url_https:\"https:\/\photo.twitter.com\/QiM55Gu93N\","media_url_https:\"https:\/\photo.twitter.com\/QiM55Gu93N\","media_url_https:\"https:\/\photo.twitter.com\/QiM55Gu93N\","media_url_https:\"https:\"https:\/\photo.twitter.com\/QiM55Gu93N\","media_url_https:\"https:\/\photo.twitter.com\/\photo.twit

lowing":null,"geo_enabled":false,"profile_banner_url":"https:\/\pbs.twimg.com\/profile_banners\/19636948\/1398372693","profile_background_image_url":"http:\/\pbs.twimg.com\/profile_background_images\/266977293\/cp24_twitter_background4.jpg","name":"CP24","lang":"en","profile_background_tile":true,"favourites_count":6,"screen_name":"CP24","notifications":null,"url":"http:\/\www.cp24.com","created_at":"Wed Jan 28 04:56:13 +0000 2009","contributors_enabled":false,"time_zone":"Eastern Time (US & Canada)",

"protected":false,"default_profile":false,"is_translator":false},"geo":null,"in_reply_to_user_id_str":null,"possibly_sensitive":false,"lang":"en","created_at":"Wed Oct 22 23:55:12 +0000
2014", "filter_level":"low", "in_reply_to_status_id_str":null,"place":null,"

extended_entities":{"media":[{"expanded_url":"http:\\/t.co\/QiM55072912957452289\/photo\/1","display_url":"pic.twitter.com\/QiM55Gu93N","url":"http:\\/t.co\/QiM55Gu93N","media_url_https:\/\/pbs.twimg.com\/media\/B0lvCCXCUAAcPFg.jpg","id_str":"525072912349286400","sizes":{"large":{"h":401,"resize":"fit","w":533},"small":{"h":255,"resize":"fit","w":340},"medium":{"h":401,"resize":"fit","w":533},"thumb":{"h":150,"resize":"crop","w":150}},"indices":[118,140],"type":"photo","id":525072912349286400,"media_url":"http:\/\/pbs.twimg.com\/media\/B0lvCCXCUAAcPFg.jpg"}]}}

En la opción que incluye tweets.json, cada json correspondiente a un tweet base incluye un atributo extra llamado "rumour": {yes|no} que indica si el tweet es un rumor o no.





Qué tienen que hacer?

Pre-procesamiento Features Léxicas



Features Sintácticas
Pipeline



Features Semánticas Modelo Clasificación

Semana 1 Semana 2 Semana 3



Qué tienen que hacer?

Pre-procesamiento Features Léxicas

- Procesar el dataset.
- Pre-procesar el texto (remover stopwords, puntuación, stemmer, lemmatization, ...)
- Definir carácterísticas léxicas para representar los tweets.
- Definir una representación para los tweets (BOW, N-grams, ...)
- Pueden considerer características que no sean textuales.
- Pueden incluir characterísticas extraídas de las reacciones.
- Analizar cómo varía el vocabulario de los tweets con la aplicación del preprocesamiento.
 - Por ejemplo, mostrar distribuciones de frecuencias, términos más frecuentes...



Qué tienen que entregar?

Pre-procesamiento Features Léxicas

- Notebook con:
 - Carga de dataset.
 - Selección de atributos de los tweets. Mencionar brevemente por qué eligieron cada uno de ellos.
 - Estadísticas del dataset.
 - Tamaño del vocabulario, términos más frecuentes, términos más frecuentes por clase...
 - Aplicación de pipeline de pre-procesamiento. Mencionar brevemente por qué eligieron cada uno de los pasos.
 - Comparación de estadísticas del dataset antes y después del pre-procesamiento.
 - Selección de características léxicas.





Qué tienen que entregar?

Pre-procesamiento Features Léxicas

Fecha de entrega: 7 de Agosto 2020

- Notebook con:
 - Carga de dataset.
 - Selección de atributos de los tweets. Mencionar brevemente por qué eligieron cada uno de ellos.
 - Estadísticas del dataset.
 - Tamaño del vocabulario, términos más frecuentes, términos más frecuentes por clase...
 - Aplicación de pipeline de pre-procesamiento. Mencionar brevemente por qué eligieron cada uno de los pasos.
 - Comparación de estadísticas del dataset antes y después del pre-procesamiento.
 - Selección de características léxicas.





Qué tienen que entregar?

Pre-procesamiento Features Léxicas

Fecha de entrega: 7 de Agosto 2020

La notebook debe poder ejecutarse sin errores y debe incluir los outputs generados!

- Notebook con:
 - Carga de dataset.
 - Selección de atributos de los tweets. Mencionar brevemente por qué eligieron cada uno de ellos.
 - Estadísticas del dataset.
 - Tamaño del vocabulario, términos más frecuentes, términos más frecuentes por clase...
 - Aplicación de pipeline de pre-procesamiento. Mencionar brevemente por qué eligieron cada uno de los pasos.
 - Comparación de estadísticas del dataset antes y después del pre-procesamiento.
 - Selección de características léxicas.







Procesamiento de Lenguaje Natural / Intro

Quiénes somos? Cómo vamos a trabajar? Evaluación?