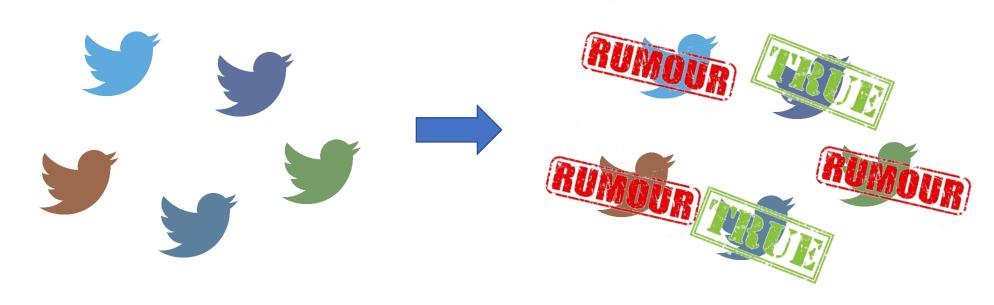


Procesamiento de Lenguaje Natural / TP

Detección de rumores en medios sociales

Cuál es el objetivo?

Detectar aquellos tweets que contienen información que todavía no ha sido verificada (los rumores), distinguiéndola de lo que no son rumores!





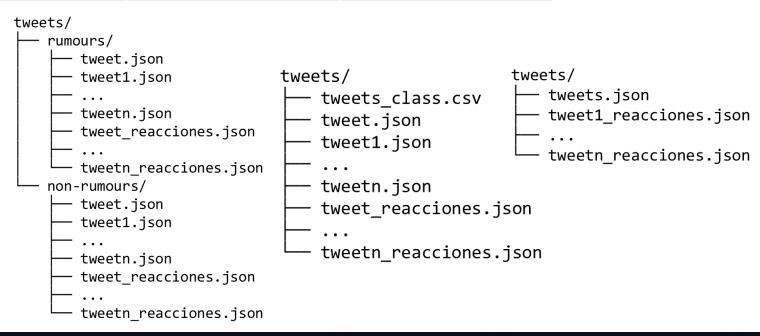


Y los datos?

- Sydney siege.
 - Un hombre armado tomó como rehenes a 10 clientes y 8 empleados en un local de Lindt en Sydney, Australia, el 15 de Diciembre de 2014.

Evento	Rumours	Non-rumours	Total
Sydney Siege	522 (42.8 %)	699 (57.2 %)	1.221

- Formato JSON → JavaScript Object Notation
- Por cada Tweet, se tiene:
 - Información completa.
 - Información completa de las reacciones.
 - Clase (Rumor o no rumor?)





Los prácticos!

Pre-procesamiento Features Léxicas



Features Sintácticas & Semánticas Pipeline

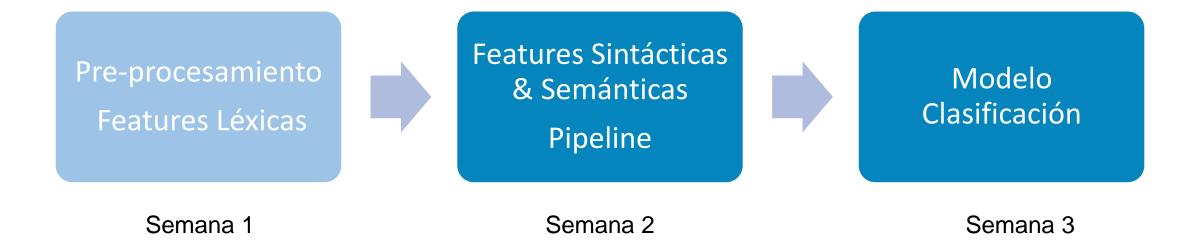


Modelo Clasificación

Semana 1 Semana 2 Semana 3



Qué hicieron hasta ahora?



Con este práctico deberían haber:

- Procesado los json con los tweets y almacenarlos en alguna estructura.
- Decidido si considerar o no las reacciones.
- Elegido algunas características para representar los tweets.
- Aplicado pasos de pre-procesamiento sobre el texto.
- Pensado en alguna estrategia para representar los tweets (opcional).
- Calculado estadísticas sobre los tweets (por ejemplo, palabras más frecuentes)





Qué hicieron hasta ahora? -> Resumen de las entregas del TP 1

- La mayoría consideró pasar a lower case.
- La mayoría consideró lemmatización.
 - Solo uno o dos probaron con stemming.
- Algunos adaptaron la lista de stopwords (sacaron negaciones).
- Algunos adaptaron los tokenizers para evitar que les separase URL, menciones y hashtags.
- Algunos adaptaron lemmatizer para evitar transformaciones de nombres de entidades.
- Algunos hicieron reemplazo de tokens (URL, hashtags y menciones).
 - De las otras características, las más seleccionadas:
 - Cantidad de favoritos y retweets.
 - Si la cuenta del usuario que compartió el tweet estaba verificada.
 - Cantidad de seguidores del usuario que compartió el tweet.
 - Fecha de publicación.
- Algunos consideraron las reacciones:
 - Texto de las reaccciones concatenado en una característica aparte.
 - Texto de las reacciones diferentes al tweet original en una característica aparte.
 - Cantidad de reacciones.





Qué hicieron hasta ahora?



Con este práctico deberían haber integrado:

- Procesamiento de los json con los tweets y almacenarlos en alguna estructura.
- Elección de las características para representar los tweets.
- Elección de la representación para los tweets.



Qué tienen que hacer?

- Entrenar modelos de clasificación de rumores!
- Elegir una técnica de selección de características para aplicar.
 - Mostrar la relevancia de las características de acuerdo a la técnica seleccionada.
- Elegir al menos dos clasificadores para entrenar.
 - En lo posible, realizar optimización de parámetros.
- Reportar resultados la clasificación con los diferentes clasificadores:
 - Aplicando o no pre-procesamiento.
 - Aplicando o no feature selection (sobre la variante con pre-procesamiento).





Qué tienen que entregar?

- Notebook con:
 - Aplicación de la técnica elegida de feature selection.
 - Entrenamiento de los clasificadores elegidos + optimización de parámetros.
 - Explicar brevemente la elección de los clasificadores.
 - Reporte de los resultados.
 - Elegir las métricas que consideren adecuadas. Explicar brevemente la elección.
 - Incluir algún gráfico comparativo.





Qué tienen que entregar?

Fecha de entrega: 21 de Agosto 2020

- Notebook con:
 - Aplicación de la técnica elegida de feature selection.
 - Entrenamiento de los clasificadores elegidos + optimización de parámetros.
 - Explicar brevemente la elección de los clasificadores.
 - Reporte de los resultados.
 - Elegir las métricas que consideren adecuadas. Explicar brevemente la elección.
 - Incluir algún gráfico comparativo.



Qué tienen que entregar?

Fecha de entrega: 21 de Agosto 2020

La notebook debe poder ejecutarse sin errores y debe incluir los outputs generados!

- Notebook con:
 - Aplicación de la técnica elegida de feature selection.
 - Entrenamiento de los clasificadores elegidos + optimización de parámetros.
 - Explicar brevemente la elección de los clasificadores.
 - Reporte de los resultados.
 - Elegir las métricas que consideren adecuadas. Explicar brevemente la elección.
 - Incluir algún gráfico comparativo.







Procesamiento de Lenguaje Natural / TP

Detección de rumores en medios sociales